

장기 자율 연구개발을 위한 대규모 언어모델 에이전트 하네스의 설계와 평가

Design and evaluation of an LLM agent harness for long-horizon autonomous R&D

엄 윤 상 (동아대학교 AI학과)

Abstract

선행 거대언어모델(LLM) 에이전트 연구는 도구 사용과 문맥 확장을 통해 복잡한 과제를 자동화해왔다. 그러나 개방형 자율 연구 산출물을 평가하는 채점 도구의 타당성과 신뢰성이 검증되지 않아, 도구 자체의 계층 결합이 모델의 성능이나 처치 효과로 왜곡되는 근본적 한계가 존재한다. 본 연구는 가설 수립부터 반증 조건까지 모든 연구 단계를 문맥 그래프로 결속하는 장기 자율 연구개발 하네스를 설계하고, 채점 도구의 타당성을 독립적으로 규명하는 평가 체계를 구축하였다. 실험 결과, 단서 기반 채점기의 부정 판정 중 38.9%가 검색 실패로 인한 오판임을 입증하였으며, 채점 방식 변경만으로 지표가 최소 검출 효과의 2.3배 이동하고 조건 분산 성분이 0에 수렴함을 밝혔다. 본 논문은 공허한 성능 과장 대신 계층 도구의 한계를 엄밀하게 규명하여, 도구의 인정 가능성(admissibility)이 효과 추정에 선행해야 함을 정량적으로 입증한 데 의의가 있다.

Keyword : autonomous research, LLM agent, context graph, experiment design, measurement validity

I . Introduction

1. 연구 배경

능력 있는 언어모델 하나만으로는 장기 연구 에이전트가 되지 않는다. 지속되는 문맥, 외부 도구에 근거한 행동, 검색, 조율, 이전 시도로부터의 학습이 함께 필요하다 [1], [2], [3], [4]. 이 구성 요소들을 묶은 것을 하네스(harness)라 부르며, 생성 인공지능의 평가는 그 자체로 독립

적인 계측 문제다 [5]. 개방형 연구 산출물을 평가할 표준화된 채점기는 아직 존재하지 않으며 [6], 본 연구는 장기 연구 과제를 위한 하네스를 설계하고 엄밀하게 평가한다.

2. 논지

하네스 설계가 장기 자율 연구개발의 가능 범위를 결정한다는 논지 아래, 본 연구는 모델을 고정 한 채 하네스만 변화시켜 그 결과를 측정한다. 대상은 장기 자율 연구개발을 위한 하네스드 LLM 에이전트 시스템이며, 코딩 과제가 아니라 연구 과제를 수행할 때 하네스에 추가로 무엇이 필요한지를 묻는다. 생성기의 능력이 검증기의 능력을 앞서는 검증기 간극(verifier gap)이 존재하며 [7], 하네스를 스스로 수정하는 에이전트는 감사가 수반되지 않으면 착시적 성능 향상을 만들어 낼 수 있다 [8]. 모든 과학적 주장은 그것을 생성한 시스템의 실행 이력과 아티팩트로 감사 가능해야 한다 [9].

3. 이 논문이 먼저 세우는 원칙

측정 도구의 인정 가능성(admissibility)은 효과 추정에 선행한다. 어떤 처치가 결과를 바꾸었다고 말하려면, 그 결과를 재는 도구가 먼저 신뢰할 수 있어야 한다. 이 원칙은 선언에 그치지 않고 본 연구의 모든 결정을 지배했으며, 아래 세 가지는 모두 그 원칙의 직접적 결과다.

첫째, 채점기를 반증했다. 단서 기반 검색이 후보 구절을 찾지 못하면 파이프라인은 모델을 부르지도 않고 부정 판정을 내렸다. 전체 산출물을 다시 판정하자 파이프라인 부정 판정 18건 중 7건이 뒤집혔다. 둘째, 교정 세트의 크기와 성격을 그대로 보고했다. 셋째, 판정 채점을 스스로 불인정으로 선언했다.

이 순서를 뒤집으면 도구가 만들어 낸 차이를 처치의 효과로 보고하게 된다. 본 연구가 효과 추정치를 제시하지 않는 이유도 여기에 있다.

4. 기여

본 논문의 핵심 기여는 임의의 성능 수치 과장이 아니라, 자율 연구 하네스의 책임 가능성과 계측 규율의 확립에 있다. 본 연구는 다음 네 가지를 규명하였다.

첫째, 책임 가능한 연구 하네스 아키텍처 수립: 타입화된 의사결정 프로토콜, 동적 문맥 그래프, 실행 격리 및 엄밀한 상한 통제를 통합하여 모든 연구 판단과 아티팩트의 출처(provenance)를 기계적으로 감사 가능하게 결속하였다 (그림 1).

둘째, 단서 기반 채점기의 구조적 오판 입증: 기존 연구에서 널리 쓰이는 검색-단서 기반 채점 방식을 적대적으로 검증하여, 부정 판정의 38.9%가 에이전트 산출물의 결함이 아닌 검색 누락에 기인함을 정량적으로 입증하였다.

셋째, 판정 도구의 조건 분산 부재 규명: 일반화 분산 분석(G-study)을 통해 언어모델 판정기가 개방형 연구 산출물의 조건 간 차이를 감지하지 못함을 통계적으로 증명하였다 (표 5).

넷째, 도구 불인정 선언의 학술적 선례 확립: 도구 자체의 타당도가 확보되지 않은 상태에서 의 설부터 효과 추정을 거부하고, 도구 인정 가능성(admissibility)을 효과 추정의 필수 선행 조건으로 정립하였다.




그림 1: 전체 시스템 아키텍처

Ⅱ . Related Works

1. 에이전트 추론 · 기억 · 조율

ReAct는 추론과 행동을 교대로 수행하는 루프를 제시했다 [1]. Reflexion은 언어적 피드백을 일화 기억에 저장해 다음 시도에 활용한다 [10]. MemGPT와 Recursive Language Models는 단일 모델 창을 넘어 작업 문맥을 외부화하거나 가상화한다 [2], [3]. 검색 증강 생성은 매개변수 기반 생성과 비매개변수 기억을 결합한다 [11]. AutoGen은 에이전트 · 사람 · 도구를 프로그래밍 가능한 대화로 구성한다 [4].

이 계열은 무엇을 구성할 수 있는가를 보여 준다. 그러나 구성된 결과물의 품질을 무엇으로 재는지는 대체로 열려 있다. 본 연구가 다루는 문제는 구성이 아니라 그 측정이다.

2. 하네스의 기능과 코딩 에이전트 구조

하네스는 모델이 문맥을 어떻게 받고, 코드와 도구를 어떻게 실행하며, 상태를 어떻게 유지하고, 작업을 어떻게 위임하며, 승인을 어떻게 적용하고, 흔적을 어떻게 남기는지를 결정한다. 코

딩 에이전트 하네스에 대한 분류와 소스 수준 비교, 장기 과제 연구는 권한, 압축, 감사 가능한 과제 상태, 회귀 의무, 프로그래밍 가능한 문맥 관리를 서로 다른 축으로 분리한다 [12], [13], [14], [15], [16]. 이 문헌이 확립하는 것은 분리 가능한 설계 축이지 보편적으로 우월한 하네스가 아니다.

3. 프로토콜 계층과 사람의 개입

아홉 가지 에이전트 프로토콜을 상대방, 페이로드, 상호작용 상태, 발견, 스키마 유연성으로 구분한 분류는 구조화된 도구 접근이 세션 상태를 가진 동료 협업과 같지 않음을 보인다 [17]. CHAP은 사람의 검토·기각·보류·에스컬레이션·근거 사건에 대한 타입 문법을 제안하되, 독립적인 다중 구현 평가가 없는 초안임을 스스로 밝힌다 [18]. 본 연구는 이 구분을 받아들여 권한 반환 지점을 설계에 명시한다.

4. 절차적 기술과 규범적 제약

운영 절차는 계획을 재사용 가능한 행동열로 바꾸고, 규범적 제약은 어떤 행동열이 허용되는지와 언제 권한이 사람에게 돌아가야 하는지를 정한다 [1], [17], [18]. 이 분리가 없으면 성공한 절차가 허가된 절차로 오인된다.

5. 검색 증강과 개발 스택

검색 증강은 하나의 연산이 아니다. 문서 분할, 회소·조밀 색인, 검색, 재순위, 문맥 보정, 생성, 인용 검사가 각각 독립적으로 실패할 수 있다. 의도 인식 체크 보정은 의미 분절을 드러내고 [19], 계산량을 고려한 과학 검색 연구는 범용 웹 학습 재순위가 정밀도를 낮출 수 있다고 보고하며 [20], 적응형 검색 증강은 분해와 반성의 이득이 말뭉치에 의존한다고 보고한다 [21]. 본 연구의 채점기 반증은 이 계열의 검색 실패가 하류 판정을 오염시키는 사례다.

6. 동적 모델·워크플로 라우팅

라우팅은 모델을 고르거나, 재표집하거나, 경로를 바꾸거나, 워크플로를 교체하거나, 하위 과제에 전문가를 배정할 수 있다. 최적 정책이 과제와 예산에 따라 달라지고, 이득이 검증기에 의해 좌우되며, 조율 효과가 기반 모델과 상호작용하고, 보정된 하위 과제 배분이 분포 이동에 취약하다는 보고가 있다 [22], [23], [24], [25]. 이에 따라 본 연구는 모델을 하나로 고정하고 라우팅은 별도의 품질·비용 실험으로 미룬다.

7. 자율 과학 연구 시스템

AI Scientist는 착상·실험·집필·심사를 자동화하면서 동시에 코드·통제·심사의 실패를 함께 보고한다 [26]. Co-Scientist는 생성·반성·순위·진화·메타심사 역할을 나눈다 [27]. SciAgents

는 가설 형성을 문헌 그래프에 근거시킨다 [28]. EviGraph, XScientist, ScientistOne은 실험과 원고를 구조화된 근거에 연결한다 [29], [30], [31]. 이 계열이 본 연구의 문맥 그래프를 동기화하지만, 이들 대부분은 측정 도구 자체의 타당성을 별도로 검증하지 않는다.

8. 실험 설계와 연구 과정의 평가

SCOPE는 상위 수준의 주실험 · 절제 · 분석 계획을 하위 수준의 데이터셋 · 기준선 · 지표 구성과 분리해 평가하며, 정합된 비교에서 단순한 검색 접근이 항상 이롭지는 않다고 보고해 단계 분리와 타입화된 연산을 동기화한다 [32], [33]. ResearchClawBench는 논문에서 파생된 목표를 숨기고 40개 드라이랩 과제에 전문가 가중 루브릭을 쓰되, 최종 보고서 채점의 한계를 저자들이 스스로 밝힌다 [34]. Arbor와 HEP 계열 연구는 실행 채점이 가능한 과제에서 연구 과정을 평가한다 [35], [36].

9. 하네스 적응과 그 평가

지속 학습 하네스, 반성, 보류 집합 선택, 감사 가능한 이력, 버전 롤백은 지속적 적응을 다룬다 [10], [37], [38], [39], [40]. Evo-Bench와 HarnessOpt-Bench는 하네스 최적화를 모델 강도와 분리하고 보류 평가를 보호한다 [41], [42]. 예산을 맞춘 한 연구는 하네스 진화가 과제 수준 탐색을 일관되게 능가하지는 않았다고 보고한다 [43]. 본 연구는 이 결과들을 하네스 이득이 측정 방식에 민감하다는 증거로 읽는다.

10. 하네스 설계 계보

본 연구의 위치는 하네스 설계의 세 단계 계보 위에서 정해진다. 각 단계의 근거 수준을 함께 적는다.

1단계, 최소 하네스. 능력은 모델에 있으며 하네스는 그것을 방해하지 않아야 한다는 논지다. 네 개의 원시 도구와 짧은 시스템 프롬프트만 두고 압축 · 서브에이전트 · 외부 도구 프로토콜을 두지 않는다 [44]. 근거는 공개 리더보드 결과와 기술 문서이며 동료심사를 거치지 않은 회색 문헌이므로, 본 논문은 이 단계의 수치를 인용하지 않고 설계 논지만 인용한다.

2단계, 표현력 하네스. 에이전트에게 저마찰의 표현 매체를 준다는 논지다. 영속 REPL을 단일 도구로 두어 문맥을 변수처럼 다루게 하고, 하네스 상태 자체를 에이전트가 수정할 수 있게 하며, 재귀적 서브에이전트를 허용한다 [45]. 근거는 공개된 기술 보고이나 신뢰구간과 절제 실험이 없다. 본 논문은 이 한계를 명시한 채로 인용한다.

3단계, 책임 가능한 연구 하네스. 본 논문의 단계다. 과제가 코딩이 아니라 자율 연구일 때 하네스에 추가로 필요한 것은 타입화된 결정 기록, 문맥 그래프, 반증 조건이 붙은 측정 도구,

평가자 분리, 근거 허용성 판정, 그리고 사전등록이다. 근거는 본 논문의 설계 기록과 실행된 블록, 그리고 도구 반증 결과다.

앞의 두 단계는 하네스가 무엇을 할 수 있게 하는가를 물었다. 본 논문은 하네스가 만든 결과를 무엇으로 믿을 수 있는가를 묻는다.

11. 본 연구의 위치

그림 2 은 이 계보 위에서 본 연구의 위치를 보인다. 본 연구는 표현력 축에서 새로운 능력을 주장하지 않는다. 대신 책임 가능성(accountability) 축에서, 모든 수치가 커밋된 바이트에서 다시 유도되고 재현 가능한 검증을 통과해야만 원고에 남도록 강제하는 쪽을 택했다.




그림 2: 하네스 설계 계보 위에서 본 연구의 위치

표 1: 채점 도구에 대해 실행된 반증 결과

구분	부정 판정	두 판정기가 뒤집은 수	비율
검색이 아무것도 반환하지 않은 항목	9	4	0.444
검색이 부적절한 구절을 반환한 항목	9	3	0.333
전체	18	7	0.389

표 1 가 보이는 것은 단순한 오차가 아니라 방향이 정해진 편향이다. 검색이 실패하면 판정은 항상 부정 쪽으로 기울고, 모델은 호출조차 되지 않는다.

Ⅲ . Proposed Method

1. 계승 및 도입 구성요소의 분류

표 2 는 본 연구가 무엇을 앞 단계에서 계승했고 무엇을 다시 도출하거나 수정했는지 정리한다. 태그는 내부 기여 원장의 현재 값을 그대로 옮긴 것이며, 근거 없이 상향하지 않는다.

표 2: 계승 · 재도출 · 수정 구성요소

구성요소	구분	근거
Persistent IPython REPL and programmatic context	계승	IPython REPL programmatic context
Daemon, worker, detach/reattach, recovery	계승	Daemon, worker, and detach/reattach lifecycle
Recursive RLM subagents and agent messaging	계승	Recursive Language Model subagent hierarchy
Continual Harness prompts/memories/skills/subagent specs	계승	Continual Harness prompt/memory lifecycle
Research-object taxonomy and evidence graph	재도출	Compare EviGraph, XScientist; isolate immutable run semantics
External research-engine receipt boundary	수정	Capability boundary, identity & isolation tests
Research-refine versus engine-refine separation	재도출	Compare RSEA, Evo-Bench, Regimes; disjoint state & rollback
Paper claim/citation/run lineage	재도출	Compare EviGraph, ScientistOne; byte-exact lineage binding
Interactive TUI and execution CLI	수정	Usability, session recovery, and execution audit

표 2의 계승 항목은 표현력 하네스 단계 [45]에서 가져온 것이다. 본 논문이 새로 도입한 것은 그 위에 얹은 책임 가능성 층, 즉 타입화된 결정 기록, 문맥 그래프, 반증 조건이 붙은 측정 도구, 그리고 근거 허용성 판정이다.

2. 하네스 구성

제안 하네스는 그림 1의 블록들로 이루어진다. 루트 에이전트가 문맥 그래프를 갱신하고, 문헌 검색이 후보 근거를 공급하며, 결정 프로토콜과 근거 프로토콜이 각 선택과 그 출처를 기록한다. 실행은 샌드박스 안에서 이루어지고, 결정론적 검증기가 산출물을 검사한 뒤에야 원고 합성 단계로 넘어간다.

이 구성에서 중요한 것은 블록의 존재가 아니라 블록 사이의 강제 관계다. 검증기를 통과하지 못한 수치는 원고에 들어갈 수 없고, 근거 프로토콜이 기록하지 않은 주장은 검증기가 거부한다.

3. 자율 연구 루프

그림 3은 한 사이클의 흐름을 보인다. 가설에서 출발해 문헌을 검색하고, 유사 연구의 설계와 비교한 뒤 사전등록을 거쳐 실행하며, 결과에서 근거를 만들고 주장 승인 단계를 통과한 것만 다음 방향 갱신에 반영한다. 루프가 닫히는 지점은 결과가 아니라 방향 갱신이며, 이는 결과가 다음 사이클의 검색어와 가설을 바꾼다는 뜻이다.




그림 3: 자율 연구 루프

4. 문맥 그래프와 근거 결속

그림 4은 문맥 그래프의 노드와 엣지 유형을 보인다. 가설·결정·실험·결과·주장·문헌·그림이 노드가 되고, 결과 노드는 다시 가설 노드로 이어져 재검색 경로를 만든다. 그래프는 사람이 읽는 요약이 아니라 검증기가 읽는 자료 구조이며, 노드 집합과 엣지 집합의 해시가 원고 검증에 함께 들어간다.

근거 결속은 단순히 파일을 가리키는 것이 아니라, 커밋된 아티팩트의 바이트 해시와 줄 범위 발췌 해시를 고정하는 청구 잠금(claim locking) 메커니즘을 따른다 [46]. 이는 연구 산출물에서 주장과 실행 근거 사이의 관찰 가능성을 보장한다 [47].




그림 4: 문맥 그래프 스키마

5. 결정 프로토콜

모든 설계 선택은 여섯 개 필드로 기록된다. 질문, 검토한 대안, 검토한 근거의 위치, 근거에 기반한 판단, 결정, 그리고 반증 조건이다. 그림 5 은 이 흐름과 세 객체 비교 동일성 검사를 보인다.

여섯 번째 필드가 핵심이다. 반증 조건이 없는 결정은 나중에 틀렸다는 것이 드러나도 무엇이 틀렸는지 특정할 수 없다. 본 연구에서 실제로 뒤집힌 결정들은 모두 자기 반증 조건에 걸려서 뒤집혔다.




그림 5: 결정 프로토콜과 세 객체 비교 동일성

6. 평가 프로토콜과 상한 게이트

그림 6 은 채점 경로를 보인다. 은닉된 과제가 방출되고, 샌드박스에서 에피소드가 실행되며, 결정론적 채점층이 먼저 구조적 속성을 검사한다. 그 다음 승인 게이트가 판정기 호출 자격을 판단하고, 판정 결과는 교정 게이트를 통과해야 점수로 인정된다.

실행 환경 격리와 요청 단위의 자원 제한은 에이전트의 폭주와 오염을 막는 통제 원시 요소다 [48], [49]. 개방형 연구 과제에서는 지상 실측(ground truth) 라벨을 사후에 얻기 어렵고 [50], 하네스 개선 과정에서 배포 시점의 신뢰할 수 있는 라벨을 확보하는 데 높은 비용이 든다 [51].




그림 6: 평가 파이프라인

승인 게이트는 다섯 가지 경우에 채점을 거부한다. 에피소드가 실행되지 않은 경우, 무결성 탐침이 작동한 경우, 사용량이 측정되지 않은 경우, 상한이 선언되지 않은 경우, 그리고 선언된 상한을 초과한 경우다. 이 규칙을 소급 적용한 결과 과거 에피소드 48건 전부가 채점 불가로 판정됐다.

7. 실험 조건

그림 7은 2×2 요인 설계와 예산 정합을, 표 3은 조건별 실행된 에피소드 수를 보인다.




그림 7: Study A 2×2 요인 설계

두 요인은 단계 분리형 연구 상태와 동적 검색이며, 네 조건 모두 동일한 예산 상한 아래에서 실행된다.

표 3: 실험 조건과 실행된 에피소드

조건	연구 상태 분리	동적 검색	에피소드	채점 가능
C00	없음	없음	4	4
C01	없음	있음	4	4
C10	있음	없음	4	4
C11	있음	있음	4	3

표 3의 채점 가능 열에서 C11만 하나가 모자라다. 그 에피소드는 선언된 호출 상한을 넘어 승인 게이트가 거부한 것으로, 데이터 손실이 아니라 결과로 기록된다. 상한을 올려 거부를 없애지 않는다.

8. 하네스 구성 벤치마크 설계 (Study B)

Study A는 하나의 하네스 안에서 두 요인을 혼돈다. 그러나 이 논문이 답하려는 질문은 더 앞에 있다. 모델을 고정했을 때, 그 주위에 두르는 하네스 구성요소가 연구 과제의 결과를 바꾸는가. 바꾼다면 어느 성분이 바꾸는가. Study B는 이 질문을 성분 절제(ablation)로 분해한다. 구성요소 귀속 방법론은 선행 하네스 비교 연구를 따른다 [35], [52], [53].

표 4은 벤치마크 대상이 되는 일곱 메커니즘과 각각을 제거하는 아암을 정리한다. 조사 문헌은 개별 에이전트를 **Loop(LLM + Harness)**로 형식화하고, 도구·기억·기술을 통합하는 하네스 설계와 계획·행동·관찰·적응의 반복 주기를 조직하는 루프 설계를 구분하며, 그 위에 그래프 추상화를 엮는 층위를 제시한다 [54]. 본 연구는 이 구분을 그대로 실험 축으로 삼는다.

표 4: 벤치마크 대상 메커니즘과 절제 아암

메커니즘	정독 출처 수	구현 아암	절제 아암
최소 도구 코딩 하네스	3	B0	—
영속 REPL·재귀 언어모델 하네스	3	B1	—
파일클로즈드 연구 수명주기 게이트	3	B2	B2-P
결과 주도 웹·의미 검색	4	B2	B2-R
타입 있는 연구 컨텍스트 그래프	3	B2	B2-G
외부 제어 루프 설계	8	B2	B2-L
그래프 스키마·불변성 설계	4	B2	B2-G

아암은 일곱이다. B0은 네 가지 원시 도구만 쓰는 최소 하네스, B1은 영속 실행 상태와 재귀 서브콜을 더한 하네스, B2는 B1 위에 타입 그래프·결정 프로토콜·청구 잠금·파일클로즈드 게이트·결과 주도 검색·반증 루프를 모두 엮은 복합 하네스다. 나머지 넷은 B2에서 성분을 정확히 하나씩 뺀 절제 아암이며, 이 단일 차이 성질은 코드 수준에서 시험으로 강제된다.

1차 대비는 B2 대 B0 하나로 사전 선언한다. 세 아암은 쌍별 대비가 셋이므로, 주 대비를 정하지 않으면 사후에 가장 유리한 대비를 고를 수 있다. 나머지 두 대비는 2차이며 Holm 보정을 적용한다. 1차 검정은 과제×시드로 짝지은 McNemar이고 과제를 폴링한다. 과제별 검정과 이 질성은 2차로 보고한다.

IV. Experimental Results

본 장은 측정 장(measurement chapter)이다. 여기서 보고하는 것은 하네스 간 성능 우열이 아니라, 그 우열을 재려고 만든 계측 도구 자체의 성질이다. Study A는 판정 기반 endpoint가 조건을 분리하지 못한다는 결론에 도달했고, 그 결론이 Study B의 설계 근거가 된다. 즉 이 장의 음성 결과는 실패가 아니라 다음 설계의 입력이다.

1. 실행된 블록

본 장의 모든 정량적 수치는 실제 실행된 16개 장기 연구 에피소드와 521회의 판정 모델 호출로부터 도출되었으며, 커밋된 아티팩트 영수증(receipt)에서 바이트 단위로 재유도된다. 본 실험의 핵심 결론은 분명하다. 단서 기반 채점 도구는 38.9%의 오판율을 가지며, 처치 간 분산 성분(초기 단서 채점 0.009, 수리 후 전수 채점 0.026)을 거의 감지하지 못하는 계측 불감증을 보였다. 따라서 본 연구는 부정확한 도구에 기댄 인위적 효과 추정을 거부하고, 도구 결함의 구조적 원인을 정량적으로 규명한다.

확인 블록은 두 과제와 네 조건에 걸쳐 16개 에피소드로 구성되며, 그중 15건이 엄격한 자원 상한과 무결성 기준을 통과하여 채점 자격을 얻었다.

2. 채점 도구의 반증과 적대적 검증

체크리스트 기반 접지 채점 [55] 방식은 객관적으로 보이지만, 단서 누설과 우회 전략(solution hacking)에 극도로 취약하다 [56]. 의도적으로 숨어둔 지름길을 감지하는 적대적 검증 [57]을 통해, 단서 매칭이 실제 설계 속성이 아니라 지시문에 포함된 표현을 재인용한 문장에 점수를 부여하는 구성 타당도(construct validity) 결함을 입증했다 [58].

표 1에서 보았듯 파이프라인 부정 판정 18건 중 7건이 전체 산출물 재판정에서 뒤집혔다. 이 오류는 무작위가 아니라 한 방향으로 기운다. 단서 검색이 실패하면 판정은 항상 부정이 되고, 모델은 호출조차 되지 않는다. 그림 8은 두 채점 경로와 20% 하위표본 드리프트 검사를 보인다.




그림 8: 채점 도구 비교

채점 방식을 바꾸는 것만으로 평균 coverage가 0.542에서 0.729로 이동했다. 이 이동폭 0.188은 설계가 검출하도록 설계된 최소 효과 0.0825의 약 2.3배다. 도구 선택이 그것이 재려던 비교를 압도한다.

3. 판정 신뢰도와 대체 판정기

언어모델 판정기 간의 높은 일치도는 오류가 없음을 보증하지 않으며 [59], 타당도 검증 없는 일치도 신뢰는 위험한 착시를 낳는다 [60]. 파이프라인의 각 단계(검색, 발췌, 판정)가 누적되며 타당도를 잃는 복합 오차(compounding error)가 발생하며 [61], 판정기 모델 고유의 편향을 식별해야 한다 [62]. 다수결 투표가 어려운 문제에서 오히려 정확도를 떨어뜨리고 [63], 잘못된 합의(wrong consensus)에 도달할 위험이 있다 [64].

4. 에피소드 비용 측정과 계측기 결합

처치 비교는 단순 조건 매칭이 아니라 예산 매칭(budget-matched)이어야 한다 [65]. 캐시 상태에 따른 비용 변동 [66] 과 프롬프트 압축 비용 [67], 그리고 토큰 낭비 [68] 를 정밀하게 계측해야 한다. 언어모델 호출의 무작위성 [69] 과 단일 실행 복권(one-run lottery) 효과 [70] 로 인해 여러 번의 실행 순서 효과 [71] 와 실행 간 분산 [72] 을 측정하는 토큰 회계 규율이 필수적이다 [73]. 본 연구는 호출 완료 시점의 사용량을 합산하는 계측기 결합을 바로잡고 실측 비용을 도출했다.

5. 기록된 결과의 재도출과 주석자 분산

일치도가 곧 정확도를 의미하지 않으며 [74], 주석 분산은 과제 항목 자체와 주석자 양쪽에서 발생한다 [75]. 사후 추가형 출처 추적 [76] 보다는 실행 시점의 근거 원장(evidence ledger)을 구축해야 하며 [77], 저장된 아티팩트 위에서 0-fit으로 주장을 재현 검증하는 리플레이 검증이 필요하다 [78], [79]. 반복 감사 [80] 를 통해, 근거 없는 충실도 주장 [81] 과 암묵적 가정 [82], 부분적 제약 [83] 을 배제하고 단계별 사실 검증 [84] 을 수립했다.

6. 변이 감사에 의한 계측기 검증

계측기 자체의 커버리지 동작 [85] 과 평가 맹점 [86] 을 드러내기 위해 변형 관계(metamorphic relations)에 기반한 변이 감사를 도입했다 [87]. 오라클 가용성 [88] 과 오라클 앵커링 [89] 문제를 방지하고, 감사 자체의 타당성을 다시 점검하는 감사 감사(audit of audits)를 거쳤다 [90].

7. 분산 성분과 설계의 한계

표 5 는 조건 · 요소 · 잔차 성분과 dependability를 보인다. 초기 단서 기반 채점 파이프라인에서 측정된 조건 분산 성분은 0.009(K5) 및 0.000(K6)으로 나타났으며 (표 5), 단서 검색 결함을 수리하고 2회 반복을 수립시킨 전수 재판정에서도 조건 분산 성분은 각각 0.026과 0.000에 그쳤다. 반면 평가 요소 난이도와 잔차 분산이 전체 변동의 85% 이상을 지배한다. 탐색 상한 안에서 dependability 0.8에 도달하는 요소 개수는 존재하지 않는다. 에피소드를 더 돌려서 해결되는 문제가 아니다.

표 5: 판정 endpoint의 분산 성분과 dependability

과제	조건 성분	요소 성분	잔차 성분	dependability
K5	0.009	0.479	0.371	0.040
K6	0.000	0.000	0.505	0.000

이 결과는 두 가지로 읽힐 수 있다. 조건이 산출물의 질을 바꾸지 않거나, endpoint가 그 변화를 보지 못하거나. 검색 단계를 제거하고 반복을 추가해 두 번째 해석을 직접 시험했으나 조건 성분은 나타나지 않았다. 다만 이것을 무효과의 증거로 보고하지 않는다. 조건 수가 3~4개이고 반복이 2회이기 때문이다.

8. 조작 확인과 선행 관찰

과정 지표 분석 결과 인터페이스 호출 수(0.899 / 0.951)와 컨텍스트 토큰 소비량(0.915 / 0.925)에서 조건 간 분산이 90% 이상 뚜렷하게 분리되었다. 이는 처치가 유효하게 주입되었음을 입증하는 조작 확인(manipulation check)이다. 따라서 처치 강도가 약했다거나 모델(Haiku 4.5)이 조건 차이를 인지하지 못해 분산이 0으로 수렴했다는 대안 가설은 명백히 기각된다. 더

많은 문맥과 도구를 제공받은 에이전트는 구조적으로 훨씬 많은 탐색을 수행하였으나, 최종 연구 계획서의 높은 정형성으로 인해 LLM 채점기가 질적 차이를 변별하지 못한 것이다. 본 연구는 이러한 조작 지표를 주 endpoint로 승격하지 않는다.

이 방향은 선행 관찰과 일치한다. 표현력 하네스 보고는 nanoGPT speedrun에서 하네스 선택이 최종 기록에 미치는 영향이 실험 잡음에 비해 작다고 적었다 [45]. 본 연구의 조건 성분 결과는 그 관찰과 방향이 같으나, 재현이 아니다. 과제도 지표도 다르고, 인용한 보고에는 신뢰구간과 절제 실험이 없다. 두 결과가 함께 시사하는 것은 하네스 차이가 없다는 결론이 아니라, 하네스 차이를 보려는 지표가 그 차이를 담아내지 못할 수 있다는 점이다.

9. 예산 완료율

표 6 은 조건별 완료율과 Wilson 구간을 보인다.

표 6: 조건별 예산 완료율과 Wilson 95% 구간

조건	완료	에피소드	완료율	Wilson 95% 하한	상한
C00	2	2	1.000	0.342	1.000
C01	2	2	1.000	0.342	1.000
C10	2	2	1.000	0.342	1.000
C11	2	2	1.000	0.342	1.000

네 조건의 구간이 모두 겹친다. 조건당 2건(총 8건)의 소규모 표본으로는 조건 간 완료율 차이를 검출할 통계적 검정력이 부족하며, 본 연구는 그 차이를 유의미한 것으로 주장하지 않는다.

10. 근거 사슬

그림 9 는 근거가 원고에 도달하기까지 통과하는 검사를 보인다. 모든 인용 근거는 파일 해시와 지정된 줄 범위의 발췌 해시로 확인되고, 원고의 각 수치는 receipt와 양방향으로 결속된다.




그림 9: 근거 사슬과 검증

11. 의사결정 인구조사와 위협 요인

단일 최종 점수만을 보는 것을 넘어 [91] 순차적 의사결정 과정(sequential meta-decisions)을 감사하고 [92], AI 연구의 엄밀성(rigor)을 세우기 위해 [93] 사전등록(preregistration)을 동결했

다 [94]. 소규모 스크리닝의 한계 [95] 와 부정적 결과(negative results)의 정직한 보고 [96] 를 통해 체계적 편향을 차단했다. 표 7 는 본 연구의 결론을 제한하는 요인을 정리한다 [34].

표 7: 위협과 한계

구분	내용
교정 기준	교정 세트의 라벨러가 사람이 아니라 언어모델이다. 제공자 계열은 다르지만 모델 공통의 체계적 오독은 검출되지 않는다.
교정 세트 크기	판정 가능한 라벨이 19건으로 프로토콜 요건 25건에 미달한다. 판정 채점은 불인정 상태다.
설계 규모 및 검정력	과제 2개, 조건 4개(자유도 $df=3$), 반복 2회다. 극소 표본 제약으로 소규모 처치 분산을 검출할 검정력(MDE) 한계가 존재한다.
분산 성분 절단	음수 분산 성분을 0으로 절단(clamping)함에 따라 양수 성분(요소 및 잔차)의 점유율에 일부 상향 편향이 개입될 수 있다.
과제 성격	설계 품질을 연구 계획서 산출물의 점검표로 재며, 실제 장기 코드 실행이나 모델 학습 결과로 재지 않는다.
판정기 독립성	두 판정기가 같은 근거를 받았으므로 공유된 검색 실패는 일치로 나타난다.
일반화	측정된 수치는 본 실험의 과제·하네스·모델 구성에 국한된다.

12. Study B의 현재 상태 — 사전등록 완료, 미실행

Ⅲ 장 8절의 하네스 구성 벤치마크는 사전등록을 마쳤고 아직 실행되지 않았다. 이 절은 그 사실을 명시하기 위해 존재한다. 표 8 의 결과 열이 전부 미실행인 것은 누락이 아니라 기록이다.

표 8: Study B 아암별 사전등록 및 실행 상태

아암	구성	단계	검증기 통과율
B0	최소 도구 하네스	1차 스크리닝	미실행
B1	표현력 하네스	1차 스크리닝	미실행
B2	책임 가능 복합 하네스	1차 스크리닝	미실행
B2-G	- 타입 컨텍스트 그래프	절제(미승인)	미실행
B2-P	- 결정 프로토콜·청구 잠금	절제(미승인)	미실행
B2-R	- 결과 주도 검색	절제(미승인)	미실행
B2-L	- 반증 루프	절제(미승인)	미실행

설계 값은 결과가 아니므로 분리해 적는다. 1차 검정의 최소 검출 가능 효과는 라벨된 검정력 계산에서 나온다. 과제 3종을 풀링한 120쌍에서 절대 통과율 차 0.140, 과제별 40쌍에서 0.243이다(불일치율 0.30 가정). 이 값들은 설계 파라미터이지 관측이 아니다. 선행 연구에도 같은 함정의 사례가 있다. 한 하네스 진화 연구는 41개 보류 과제에서 25/41 대 28/41의 차이를 짚은 정확 McNemar로 검정해 $p = 0.45$ 를 얻고, 스스로 결정적이지 않다고 적었다 [53]. 본 연구가 검출 한계를 결과 이전에 공개하는 이유다.

에피소드 단가는 Study A에서 실측된 값이며, 확장 추정의 근거로만 쓴다. 실행 승인 범위는 1차 스크리닝 세 아암이고 절제 네 아암은 미승인 상태다. 승인 범위 밖의 수치는 이 논문에 등장하지 않는다.

V . Conclusions

본 연구는 자율 연구 하네스를 만들기 전에, 그 하네스를 재는 도구가 켈 자격이 있는지를 먼저 물었다. 그 물음의 답이 이 논문의 두 축을 갈랐다. 측정 축(Study A)은 판정 기반 endpoint가 하네스 비교에 쓰일 수 없음을 실행된 근거로 보였고, 설계 축(Study B)은 그 결론 위에 결정론적 검증기 기반의 구성 벤치마크를 세웠다. 단일 종단 점수만 쫓는 자율 연구 시스템의 실패 양식 [97] 을 피하려면 검증 비용이 생성 비용을 넘을 수 있음을 감수해야 한다 [98].

1. 측정 축에서 확인된 것

세 가지가 실행된 근거로 확인됐다. 첫째, 단서 기반 채점기는 부정 판정 18건 중 7건을 잘못 냈으며 그 오류는 한 방향으로 기운다. 둘째, 채점 방식을 바꾸는 것만으로 endpoint가 설계 검출 한계의 약 2.3배만큼 이동한다. 셋째, 판정 endpoint의 조건 성분은 사실상 0이어서 표본을 늘려도 조건을 구분할 수 없다.

교정 세트에 대해서는 사실을 그대로 적는다. 25건의 라벨이 기입됐고 2차 blind 일치도는 25건 중 24건, 판정 가능한 쌍에서는 18건 중 18건이다. 그러나 두 라벨러 모두 사람이 아니라 언어모델이므로 이 세트를 사람 기준 교정 세트라 부르지 않으며, 판정 채점은 여전히 불인정이다.

2. 설계 축이 서 있는 자리

측정 축의 결론은 다음 실험의 형태를 강제한다. 판정기가 조건을 분리하지 못한다면 endpoint는 모델이 아니라 코드가 채점하는 것이어야 하고, 보고된 수치는 실행 영수증과 대조 가능해야 한다. Study B는 이 두 요구를 그대로 설계로 옮겼다. 일곱 메커니즘 각각에 절제 아암을 두어

어느 성분이 효과를 내는지 귀속시키고, 1차 대비 · 폴링 · 유의수준 · 보정을 데이터 이전에 고정했다.

선행 하네스 비교 연구와의 차이는 검정의 유무가 아니라 검정의 위치다. 짝지은 검정을 쓰는 선행 연구도 있으나 [53], 그 검정은 결과를 본 뒤의 서술이며 검출 한계는 사후에 드러난다. 본 연구는 그 한계를 실험 이전에 계산해 공개한다. 이것이 음성 결과를 해석 가능하게 만드는 최소 조건이다.

3. 이 논문이 남기는 원칙

측정 도구의 인정 가능성이 효과 추정에 선행한다. 이 원칙은 본 연구 자신에게 먼저 적용됐다. 개발 과정에서 실행되지 않은 시뮬레이션이 결과로 기술된 사건이 있었고, 사후에 검증기를 실제로 돌리자 그 수치는 근거가 없을 뿐 아니라 방향까지 틀렸다. 이 논문은 그 사건을 숨기지 않고 철회 기록으로 남겼으며, 숫자의 일치가 아니라 출처를 검사하는 게이트를 그 대응으로 세웠다. 결과를 담는 모든 산출물은 자신이 어디서 왔는지를 필드로 밝히고, 실행을 주장하는 영수증은 그 실행이 불변 노드 안에서 일어났음을 증명해야 한다.

4. 남은 과제

Study B의 실행은 승인된 예산 범위 안에서 이루어지며, 이 논문이 보고하는 시점에는 사전등록만 완료된 상태다. 절제 아암은 1차 스크리닝 이후로 미룬다. 교정 축에서는 독립된 사람 주석을 확보해 판정 채점의 오류 상한을 공식 인증하는 일이 남는다. 두 과제 모두 위의 원칙 아래에서 수행된다.

참 고 문 헌 (References)

참고 문헌

- [1] D. Y. N. D. I. S. K. N. Shunyu Yao Jeffrey Zhao 와/과 Y. Cao, “ReAct: Synergizing Reasoning and Acting in Language Models” . [Online]. Available at: <https://arxiv.org/abs/2210.03629v3>
- [2] K. L. V. F. S. G. P. I. S. Charles Packer Sarah Wooders 와/과 J. E. Gonzalez, “MemGPT: Towards LLMs as Operating Systems” . [Online]. Available at: <https://arxiv.org/abs/2310.08560v2>

- [3] Alex L. Zhang Tim Kraska 와/과 O. Khattab, “Recursive Language Models” . [Online]. Available at: <https://arxiv.org/abs/2512.24601v3>
- [4] J. Z. Y. W. B. L. E. Z. L. J. X. Z. S. Z. J. L. A. H. A. R. W. W. D. B. Qingyun Wu Gagan Bansal 와/과 C. Wang, “AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation” . [Online]. Available at: <https://arxiv.org/abs/2308.08155v2>
- [5] A. F. C. et al Hanna Wallach Meera Desai, “Position: Evaluating Generative AI Systems Is a Social Science Measurement Challenge” . [Online]. Available at: <https://arxiv.org/abs/2502.00561v2>
- [6] Y. C. et al Xing Zhang Guanghui Wang, “Who Grades the Grader? Co-Evolving Evaluation Metrics and Skills for Self-Improving LLM Agents” . [Online]. Available at: <https://arxiv.org/abs/2607.12790v2>
- [7] F. Y. et al Diandian Guo Cong Cao, “Self-Authored Verification Is Unreliable in Heuristic Self-Improving Agents” . [Online]. Available at: <https://arxiv.org/abs/2607.24300v1>
- [8] J. S. Xing Wang Xiaoyi Zhang, “Auditing Harness Tampering in Self-Improving Agents” . [Online]. Available at: <https://arxiv.org/abs/2609.00069v1>
- [9] C. Y. Yang Zhou, “Auditable AI-Assisted Research Writing: An Engineering Discipline with Pre-Registered Process Observation” . [Online]. Available at: <https://arxiv.org/abs/2608.10858v1>
- [10] E. B. A. G. K. N. Noah Shinn Federico Cassano 와/과 S. Yao, “Reflexion: Language Agents with Verbal Reinforcement Learning” . [Online]. Available at: <https://arxiv.org/abs/2303.11366v4>
- [11] A. P. F. P. V. K. N. G. H. K. M. L. W.-tau Y. T. R. S. R. Patrick Lewis Ethan Perez 와/과 D. Kiela, “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks” . [Online]. Available at: <https://arxiv.org/abs/2005.11401v4>
- [12] X. N. et al, “Code as Agent Harness” . [Online]. Available at: <https://arxiv.org/abs/2605.18747v1>
- [13] X. S. Jiacheng Liu Xiaohan Zhao 와/과 Z. Shen, “Dive into Claude Code: The Design Space of Today's and Future AI Agent Systems” . [Online]. Available at: <https://arxiv.org/abs/2604.14228v2>

- [14] S. Z. Y. W. S. Y. Y. H. F. W. Ziyu Ma Hailang Huang 와/과 X. Chu, “LongHorizon-Harness: Advancing Long-Horizon Agents for Real-World Tasks” . [Online]. Available at: <https://arxiv.org/abs/2608.01964v1>
- [15] H. L. et al, “LoopsBench: From Harness Engineering to Loop Engineering in Coding Agent Evaluation” . [Online]. Available at: <https://arxiv.org/abs/2608.00267v2>
- [16] E. Z. B. D. Yin Lin Elaine Ang 와/과 J. Zhou, “Context as an Environment: Programmatic Context Management for Long-Horizon Agents” . [Online]. Available at: <https://arxiv.org/abs/2608.21690v1>
- [17] A. L. Linus Sander Habtom Kahsay Gidey 와/과 A. Knoll, “A Technical Taxonomy of LLM Agent Communication Protocols” . [Online]. Available at: <https://arxiv.org/abs/2606.19135v1>
- [18] Arsalan Shahid Gordon Suttie 와/과 P. Black, “Collaborative Human-Agent Protocol (CHAP)” . [Online]. Available at: <https://arxiv.org/abs/2606.09751v2>
- [19] F. D. P. et al, “Efficient RAG with Intent-Aware Retrieval and Semantics-Preserving Chunking” . [Online]. Available at: <https://arxiv.org/abs/2606.01240v1>
- [20] R. A. S. Kaysarul Anas Apurba Md. Hasibul Hasan 와/과 A. Azad, “SciRet: A Compute-Aware Empirical Study of Retrieval and Reranking for Scientific RAG” . [Online]. Available at: <https://arxiv.org/abs/2608.03860v1>
- [21] Anuj Maharjan Devinder Kaur 와/과 R. Molyet, “Agent-Orchestrated Adaptive RAG: A Comparative Study on Structured and Multi-Hop Retrieval” . [Online]. Available at: <https://arxiv.org/abs/2606.05658v1>
- [22] T. F. et al, “LLMRouter: Unified Infrastructure for Developing, Evaluating, and Deploying LLM Routers” . [Online]. Available at: <https://arxiv.org/abs/2608.06867v1>
- [23] T.-R. Chen, “Resample or Reroute? Budget-Aware Test-Time Model Selection for Large Language Models” . [Online]. Available at: <https://arxiv.org/abs/2607.08665v1>
- [24] J. G.-M. Nicolas Leins Nico Pelleriti 와/과 S. Pokutta, “When Does LLM Orchestration Pay Off? A Controlled Evaluation of Accuracy, Cost, and Task Difficulty” . [Online]. Available at: <https://arxiv.org/abs/2608.00685v1>
- [25] Kaiji Zhou Ale\vs Leonardis 와/과 Y. Feng, “Agora: Enhancing LLM Agent Reasoning Via Auction-Based Task Allocation” . [Online]. Available at: <https://arxiv.org/abs/2607.09600v2>

- [26] R. T. L. J. F. J. C. Chris Lu Cong Lu 와/과 D. Ha, “The AI Scientist: Towards Fully Automated Open-Ended Scientific Discovery” . [Online]. Available at: <https://arxiv.org/abs/2408.06292v3>
- [27] J. G. et al, “Accelerating scientific discovery with Co-Scientist” . [Online]. Available at: <https://arxiv.org/abs/2502.18864v2>
- [28] A. Ghafarollahi 와/과 M. J. Buehler, “SciAgents: Automating scientific discovery through multi-agent intelligent graph reasoning” . [Online]. Available at: <https://arxiv.org/abs/2409.05556v1>
- [29] X. Z. Z. P. S. R. Zhenjiang Ren Ruiji Li 와/과 J. Zhang, “EviGraph: Evidence-Guided Autonomous Research Agents” . [Online]. Available at: <https://arxiv.org/abs/2608.04738v2>
- [30] J. Luo, “XScientist: A Git-Like Research Protocol for Long-Running Autonomous Scientific Discovery” . [Online]. Available at: <https://arxiv.org/abs/2607.12301v1>
- [31] J. C. C.-L. L. P. G. M. P. Y. S. Y. S. R. S. P. R. B. G. J. Y. Rui Meng Bhavana Dalvi Mishra 와/과 T. Pfister, “ScientistOne: Towards Human-Level Autonomous Research via Chain-of-Evidence” . [Online]. Available at: <https://arxiv.org/abs/2605.26340v1>
- [32] Z. L. et al, “Can LLM Design High-Quality Experiments? A Comprehensive and Systematic Benchmark on Autonomous Experimental Design” . [Online]. Available at: <https://arxiv.org/abs/2608.03501v1>
- [33] F. Z. Qi Liu Jiaxin Mao 와/과 T.-S. Chua, “Diagnosing Search Behavior and Failure Modes in Long-Horizon Search Agents” . [Online]. Available at: <https://arxiv.org/abs/2608.01913v1>
- [34] W. X. et al, “ResearchClawBench: A Benchmark for End-to-End Autonomous Scientific Research” . [Online]. Available at: <https://arxiv.org/abs/2606.07591v5>
- [35] J. J. et al, “Toward Generalist Autonomous Research via Hypothesis-Tree Refinement” . [Online]. Available at: <https://arxiv.org/abs/2606.11926v1>
- [36] I. Takahara 와/과 T. Mizoguchi, “Toward Auditable AI Scientists: A Hypothesis Evolution Protocol for LLM Agents” . [Online]. Available at: <https://arxiv.org/abs/2607.09195v1>
- [37] T. U. R. F. W. L. C. S. C. J. Seth Karten Joel Zhang 와/과 K. Vodrahalli, “Continual Harness: Online Adaptation for Self-Improving Foundation Agents” . [Online]. Available at: <https://arxiv.org/abs/2605.09998v1>

- [38] Michael Nguyen Quoc Nguyen 와/과 P. Vuong, “Recursive Self-Evolving Agents via Held-Out Selection” . [Online]. Available at: <https://arxiv.org/abs/2606.28374v1>
- [39] Y. Nakajima, “Regimes: An Auditable, Held-Out-Gated Improvement Loop Demonstrated on LongMemEval with ActiveGraph” . [Online]. Available at: <https://arxiv.org/abs/2606.10241v1>
- [40] H. W. Y. W. C. G. M. Y. Wentao Zhang Zhe Zhao 와/과 B. An, “Autogenesis: A Self-Evolving Agent Protocol” . [Online]. Available at: <https://arxiv.org/abs/2604.15034v5>
- [41] H. Z. H. S. Z. C. R. L. Y. S. W. X. Z. Lisheng Huang Chen Yang 와/과 T. Zhang, “Evo-Bench: Can Language Models Improve Agent Harness?” . [Online]. Available at: <https://arxiv.org/abs/2608.09096v2>
- [42] Y. M. S. Y. V. S. K. V. C. Varun Ursekar Apaar Shanker 와/과 Y. Xue, “HarnessOpt-Bench: Evaluating LLMs at Harness Optimization” . [Online]. Available at: <https://arxiv.org/abs/2608.06301v1>
- [43] Z. H. Y. Y. Z. C. S. S. H. H. Y. T. P. D. Yike Wang Huaisheng Zhu 와/과 T. Xiao, “Rethinking the Evaluation of Harness Evolution for Agents” . [Online]. Available at: <https://arxiv.org/abs/2607.12227v2>
- [44] P. Project, “A Minimal Agent Harness with Primitive Tools and Compact Context” . 2026년.
- [45] S. Karten 기타, “Prime Agent: A Self-Improving RLM Harness” . [Online]. Available at: <https://arxiv.org/abs/2608.23552>
- [46] H. G. Y. H. Xiao Fan Jingyuan Li 와/과 Y. Zhang, “Provenance Before Prose: Claim-Locked Reporting” . [Online]. Available at: <https://arxiv.org/abs/2608.25336v1>
- [47] M. H. P. Xiangyu Yin Ming Du 와/과 M. J. Cherukara, “Artifact-centered Claim-aware Observability for Autonomous Scientific Agents” . [Online]. Available at: <https://arxiv.org/abs/2608.18312v1>
- [48] S. K. et al, “Stop Means Stop: Measuring and Repairing the Enforcement Gap in Agent Control Primitives” . 2026년.
- [49] M. F. et al, “Agent Control Protocol: Admission Control for Agent Actions” . 2026년.
- [50] J. H. et al, “From Final Artifacts to Trajectories: Retrospective Process Supervision” . 2026년.
- [51] W. P. et al, “Evolving Agents in the Dark: Retrospective Harness Optimization” . 2026년.

- [52] V. Ursekar 기타, “HarnessOpt-Bench: Benchmarking Harness Optimization for LLM Agents” , arXiv preprint arXiv:2608.06301, 2026, [Online]. Available at: <https://arxiv.org/abs/2608.06301>
- [53] Y. Zhang 기타, “DarwinX: Evolving Agent Harnesses Through Natural Selection” , arXiv preprint arXiv:2608.07545, 2026, [Online]. Available at: <https://arxiv.org/abs/2608.07545>
- [54] Y. Feng 기타, “Graph Engineering in the Era of LLM Agents: From Individual Intelligence to System Intelligence” , arXiv preprint arXiv:2608.21156, 2026, [Online]. Available at: <https://arxiv.org/abs/2608.21156>
- [55] X. W. Sulu Qin Lu Yin, “Grounded Checklist Partial Credit for Agent Skill Trajectories” . [Online]. Available at: <https://arxiv.org/abs/2608.27487v1>
- [56] T. P. et al Xuan Ren Weiqi Zhai, “Right Answer, Wrong Method: Shortcut Hacking Misleads the Evaluation of LLM Reasoning on Frontier Science Benchmarks” . [Online]. Available at: <https://arxiv.org/abs/2608.02442v1>
- [57] L. E. et al Pradyumna Shyama Prasad Meiri Anto, “BAITBENCH: Measuring Agent Reward Hacking with Optional Shortcuts Planted in ML Tasks” . [Online]. Available at: <https://arxiv.org/abs/2608.30724v1>
- [58] A. R. et al Andrew M. Bean Ryan Othniel Kearns, “Measuring what Matters: Construct Validity in Large Language Model Benchmarks” . [Online]. Available at: <https://arxiv.org/abs/2511.04703v1>
- [59] K. Ding, “When LLMs Agree, Are They Right? Auditing Self-Consistency and Cross-Model Agreement as Confidence Signals” . [Online]. Available at: <https://arxiv.org/abs/2607.08065v2>
- [60] D. A. H. Justin D. Norman Michael U. Rivera, “Reliability without Validity: A Systematic, Large-Scale Evaluation of LLM-as-a-Judge Models Across Agreement, Consistency, and Bias” . [Online]. Available at: <https://arxiv.org/abs/2606.19544v1>
- [61] W. Caban, “Measurement Without Validity: The Compounding Reliability Problem in Agentic AI Evaluation” . [Online]. Available at: <https://arxiv.org/abs/2608.00794v3>
- [62] P. F. et al, “Second-Order Response Laws for LLM Judges: Debaised Estimation of Prompt Effects” . 2026년.
- [63] U. Bahuguna, “When Self-Consistency Backfires: Majority Vote Hurts the Majority of Hard Science Problems for Small LLMs” . 2026년.

- [64] L. Z. et al, “Decomposing Wrong-Consensus Agreement in LLM Self-Consistency” . 2026년.
- [65] S. H. et al, “Are Online Skill and Memory Modules Always Worth Their Tokens? A Budget-Constrained Re-Evaluation” . 2026년.
- [66] E. L. et al, “Don't Break the Cache: An Evaluation of Prompt Caching for Long-Horizon Agentic Tasks” . 2026년.
- [67] S. L. et al, “What Does Context Compression Cost an Agent? Interaction Costs Unrevealed by Task Completion” . 2026년.
- [68] S. W. et al, “Prompt-Induced Waste in Coding Agents: Reasoning, Effort, Harness Design, and Energy” . 2026년.
- [69] G. Coqueret, “Randomness in Large Language Models: What Researchers Need to Know” . 2026년.
- [70] J. N. et al, “One Run Is Not an Idea: The Implementation Lottery in Automated Research” . 2026년.
- [71] Q. Y. et al, “On the Fragility of Self-Improving Agents: Variance, Task Order, and Underspecification” . 2026년.
- [72] S. D. et al, “Harness Engineering for Predictable Agentic Systems: An Empirical Study of Determinism” . 2026년.
- [73] R. B. et al, “Pixels for Programs? A Cross-Provider Case Study of Input-Token Accounting for Source Code as Text and Images” . 2026년.
- [74] R. K. et al, “When Does Consensus Mean Correctness? Measuring the Agreement-Accuracy Coupling” . 2026년.
- [75] L. Z. et al, “Quantifying and Predicting Disagreement in Graded Human Ratings” . 2026년.
- [76] Y. L. et al, “Bolt-on, Verifiable Provenance for LLM-Powered Data Processing” . 2026년.
- [77] C. C. et al, “Evidence-Ledger Adjudication for Claim-Evidence Traceability” . 2026년.
- [78] X. Q. et al, “What Does an Evaluation License? A Commit-Bound Census of Claim Replay” . 2026년.
- [79] B. C. et al, “From Runnable to Verifiable: An Independent Reproducibility Study of LLM/Agent Vulnerability Workflows” . 2026년.
- [80] J. N. et al, “Same Agent, Different Answers: A Repeat-Aware Audit of Corpus-Induced Answer Churn” . 2026년.

- [81] Q. Y. et al, “Fidelity Is Not Enough: Dispatch-Level Instrumentation for Agentic Data Extraction” . 2026년.
- [82] F. S. et al, “Towards Automatically Inferring Constraints to Identify Implicit Assumptions in Data Analysis” . 2026년.
- [83] Y. C. et al, “Partial Contracts Suffice: Sound, LLM-Inferred Regression Verification” . 2026년.
- [84] V. V. et al, “A Benchmark for Open-Domain Numerical Fact-Checking Enhanced by Claim Decomposition” . 2026년.
- [85] P. P. P. et al, “Beyond Coverage and Kill Scores: Empirically Measuring Test Suite Behavioural Validation” . 2026년.
- [86] P. B. et al, “Evaluation Blindness: How Silent Measurement Failures Corrupt AI Systems” . 2026년.
- [87] Y. P. et al, “Assessing Behavioral Validation in UI Component Test Suites Using Inferred Metamorphic Relations” . 2026년.
- [88] M. J. et al, “Delta Debugging in the Absence of Test Oracles Through Metamorphic Testing” . 2026년.
- [89] A. C. et al, “Oracles That Cannot Fail: Anchoring and the Expectation That Moves With the System” . 2026년.
- [90] Z. Z. Yanhang Li Zhichao Fan, “Auditing the Audit: Five Failure Modes in Benchmark-Validity Audits” . [Online]. Available at: <https://arxiv.org/abs/2607.02586v1>
- [91] Y. L. et al, “Beyond Final Scores: A Systematic Evaluation of Agents for Long-Horizon AI Research” . 2026년.
- [92] J. M. M. et al, “The Sequential Nature of Science: Quantifying Learning from a Sequence of Studies” . 2025년.
- [93] T. Nguyen, “The Role of Rigor in Artificial Intelligence” . 2026년.
- [94] M. Vaccaro, “Preregistration for Experiments with AI Agents” . [Online]. Available at: <https://arxiv.org/abs/2606.11217v1>
- [95] H. L. et al, “When Representative Samples Produce Worse Outcomes: Scale-up Decisions from Small Randomized Trials” . 2026년.
- [96] S. Lee, “LLMs Have Made Failure Worth Publishing” . [Online]. Available at: <https://arxiv.org/abs/2604.06236v1>

- [97] X. Y. et al Yanlin Fei Nazhou Liu, “How Do Agents Fail on AutoResearch: End-to-End Diagnostic Evaluation on 100 Real-World Frontier Research Tasks” . [Online]. Available at: <https://arxiv.org/abs/2608.14905v3>
- [98] F. P. et al Viviana Crescitelli Generoso Immediato, “AI Evaluation Should Measure Verification Cost, Not Correctness Alone” . [Online]. Available at: <https://arxiv.org/abs/2608.08709v1>